

Ускорение семплирования из диффузионных моделей с использованием состязательных сетей

Охотников Никита Владимирович

МФТИ

2023

Цели исследования

Цель

Модифицировать классическую диффузионную модель для существенного ускорения процесса семплирования

Задача

Проанализировать способы моделирования мультимодального распределения в обратном диффузионном процессе

Предлагается

Использовать неявную генеративную модель – состязательную сеть на каждом шаге диффузионного процесса

Необходимо

Рассмотреть различные постановки минимизационной задачи для используемой модели

Неявное моделирование обратного диффузионного процесса

Диффузионный процесс


▶ Прямой:

$$q(\mathbf{x}_t | \mathbf{x}_{t-1}) = \mathcal{N}(\mathbf{x}_t; \mathbf{x}_{t-1} \sqrt{1 - \beta_t}, \beta_t \mathbf{I})$$

где $t = \overline{0}, \overline{T}$, \mathbf{x}_0 – семпл из исходного распределения, \mathbf{x}_t – семпл на шаге t , $\beta_t \in (0, 1)$

▶ Обратный:

$$p_{\theta}(\mathbf{x}_{t-1} | \mathbf{x}_t) \underset{T \gg 1}{\approx} \mathcal{N}(\mathbf{x}_{t-1}; \mu_{\theta}(\mathbf{x}_t, t), \Sigma_{\theta}(\mathbf{x}_t, t))$$



Предложение

- ▶ Использовать неявную модель для восстановления распределения

Мотивация

- ▶ Моделирование мультимодального распределения для существенного уменьшения T

Основные предположения

- ▶ Марковость обратного процесса
- ▶ Нормальность и следовательно унимодальность $p_{\theta}(\mathbf{x}_{t-1} | \mathbf{x}_t)$

Диффузионная модель

Описание

В основе модели лежит постепенное добавление случайного нормального шума с коэффициентом $\beta_t \in (0, 1)$ в семпл \mathbf{x}_0 из исходного распределения в прямом процессе и постепенное восстановление распределения в обратном.

Прямой процесс

$$q(\mathbf{x}_t | \mathbf{x}_{t-1}) = \mathcal{N}(\mathbf{x}_t; \mathbf{x}_{t-1} \sqrt{1 - \beta_t}, \beta_t \mathbf{I})$$

где $t = \overline{0}, \overline{T}$, \mathbf{x}_t – семпл на шаге t . В таком случае, принимая $\alpha_t = 1 - \beta_t$, $\overline{\alpha}_t = \prod_{i=1}^t \alpha_i$ можно записать:

$$q(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \sqrt{\overline{\alpha}_t} \mathbf{x}_0, (1 - \overline{\alpha}_t) \mathbf{I})$$

Таким образом, при достаточно больших T со сколь угодно большой точностью $\mathbf{x}_T \sim \mathcal{N}(0, \mathbf{I})$, а значит обратный процесс начинается с нормального шума.

После некоторых математических преобразований получаем минимизационную задачу:

$$\sum_{t=1}^n \mathbb{E}_{\mathbf{x}_1 \dots \mathbf{x}_T} KL(q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) || p_{\theta}(\mathbf{x}_{t-1} | \mathbf{x}_t)) \rightarrow \min$$

Обратный процесс

В приближении $T \gg 1$ распределение каждого следующего семпла в обратном процессе обусловлено только на предыдущий, а также нормально.

$$p_{\theta}(\mathbf{x}_{t-1} | \mathbf{x}_t) \underset{T \gg 1}{\approx} \mathcal{N}(\mathbf{x}_{t-1}; \mu_{\theta}(\mathbf{x}_t, t), \Sigma_{\theta}(\mathbf{x}_t, t))$$

Если $\mathbf{X} = (\mathbf{x}_0^1 \dots \mathbf{x}_0^n) \sim p_0(\mathbf{x})$, то из метода максимального правдоподобия:

$$\theta = \underset{\theta}{\operatorname{argmax}} p(\mathbf{X} | \theta) = \underset{\theta}{\operatorname{argmax}} \sum_{i=1}^n \log p(\mathbf{x}_0^i | \theta)$$

Постановка задачи

Проблема

При существенном уменьшении числа шагов обратного диффузионного процесса ($T \gtrsim 1$) предположения марковости и тем более нормальности $p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)$ очевидно не верны. Кроме того, $p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)$ мультимодальное.

Задача

Предложить неявную модель для аппроксимации мультимодального распределения в обратном процессе.

Метод

По аналогии с классической диффузионной моделью будем минимизировать некоторую меру близости между распределениями D_{adv}

$$\sum_{t=1}^n \mathbb{E}_{\mathbf{x}_1 \dots \mathbf{x}_T} D_{adv} (q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) || p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)) \xrightarrow{\theta} \min$$

где D_{adv} , в случае состязательных сетей, есть некоторая f-дивергенция или метрика Вассерштайна.

Дискриминатор

Будем тренировать дискриминатор отличать сгенерированные генератором, обусловленным на \mathbf{x}_{t-1}^{fake} , семплы \mathbf{x}_t^{fake} от полученных зашумлением семплов из исходного распределения \mathbf{x}_t^{real} .

Зададим в таком случае дискриминатор как $D_\varphi(\mathbf{x}_{t-1}, \mathbf{x}_t, t)$, где φ – обучаемые параметры.

Для начала используем схему тренировки для non-saturating GAN¹, как ранее было предложено², тогда задача минимизации для дискриминатора:

$$\min_{\varphi} \sum_{t \geq 1}^n \mathbb{E}_{q(\mathbf{x}_t)} [\mathbb{E}_{q(\mathbf{x}_{t-1}|\mathbf{x}_t)} [-\log(D_\varphi(\mathbf{x}_{t-1}, \mathbf{x}_t, t))] + \mathbb{E}_{p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)} [-\log(1 - D_\varphi(\mathbf{x}_{t-1}, \mathbf{x}_t, t))]]$$

¹<https://doi.org/10.48550/arxiv.1406.2661>

²<https://doi.org/10.48550/arxiv.2112.07804>

Введение GAN моделей

Генератор

Введем генератор $G_\theta(x_{t-1}^{fake}, \mathbf{z}, t)$ с параметрами θ , латентной переменной $\mathbf{z} \sim \mathcal{N}(0, \mathbf{I})$, обусловленный на x_{t-1}^{fake} и порождающий семплы из исходного распределения. В таком случае целевое распределение в обратном диффузионном процессе:

$$p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t) := \int p_\theta(\mathbf{x}_0|\mathbf{x}_t)q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)d\mathbf{x}_0 = \int p(\mathbf{z})q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0 = G_\theta(\mathbf{x}_t, \mathbf{z}, t))d\mathbf{z}$$

При известном дискриминаторе тренируем генератор на максимизацию

$$\max_{\theta} \sum_{t \geq 1}^n \mathbb{E}_{q(\mathbf{x}_t)} \mathbb{E}_{q(\mathbf{x}_{t-1}|\mathbf{x}_t)} [\log(D_\varphi(\mathbf{x}_{t-1}, \mathbf{x}_t, t))]$$